

IITMO
MFML
Lab 1 & Lab 2
Team 7

Ишутина, Леоненко, Лопатенко, Терентьева

LAB 1 (SVD, PCA)

Основная проблема: Линейная неразделимость



- Высокая корреляция признаков
- Нелинейные зависимости в данных
- Перекрывание классов в feature space

Потенциальное решение: SVD/PCA

- Снижение размерности: 30 → 3 компоненты (97% дисперсии)
- Декорреляция признаков
- Улучшение интерпретируемости

Хотим:


- Выделение главных компонент
- Ускорение обучения MLP при сохранении качества классификации



Breast Cancer Wisconsin (Diagnostic)		
Donated on 10/31/1995		
Diagnostic Wisconsin Breast Cancer Database.		
Dataset Characteristics	Subject Area	Associated Tasks
Multivariate	Health and Medicine	Classification
Feature Type	# Instances	# Features
Real	569	30

W. Wolberg, O. Mangasarian, N. Street, and W. Street. "Breast Cancer Wisconsin (Diagnostic)," UCI Machine Learning Repository, 1993. [Online]. Available: <https://doi.org/10.24432/C5DW2B>.

LAB 1 (SVD, PCA)






СРАВНЕНИЕ ВСЕХ ЯДЕР KERNEL PCA

LINEAR : точность=0.916, KPCA_time=2860.726s, MLP_time=0.225s
POLY : точность=0.811, KPCA_time=50.584s, MLP_time=0.032s
RBF : точность=0.629, KPCA_time=3450.534s, MLP_time=0.034s
SIGMOID : точность=0.923, KPCA_time=630.521s, MLP_time=0.309s

Таблица сравнения ядер:

Ядро	Точность	Время KPCA (с)	Время MLP (с)	Общее время (с)	Компонент
LINEAR	0.916084	2860.725626	0.224862	2860.950488	3
POLY	0.811189	50.584140	0.031966	50.616106	3
RBF	0.629371	3450.533603	0.033631	3450.567234	3
SIGMOID	0.923077	630.520690	0.308946	630.829635	3

Сравнение точности всех ядер Kernel PCA



LAB 2 (BFGS)

Что делалось:

- В первой части реализована оптимизация выпуклой квадратичной функции с аналитическим и численным градиентом. Проверялась корректность градиента и скорость сходимости BFGS и L-BFGS.
- Во второй части — переход к практической ML-задаче классификации. Построена логистическая регрессия с использованием Adam и квазиньютоновских методов.
- Использован датасет с первой лабораторной Breast Cancer Wisconsin (sklearn).

Методы и реализация:

- Модель: логистическая регрессия с сигмоидой, вручную реализованный log-loss (кросс-энтропия).
- Оптимизаторы: BFGS, L-BFGS, Adam
- Гиперпараметры Adam: $\text{lr} \in \{0.01, 0.001, 0.0001\}$.

LAB 2 (BFGS)

Результаты и наблюдения:

- На квадратичной функции — BFGS и L-BFGS сходятся точно к минимуму за считанные итерации.
- На задаче Breast Cancer все методы достигли высокой точности (>95%) и низкого log-loss.
- L-BFGS почти не уступает в точности BFGS.
- Adam более чувствителен к шагу обучения, но обеспечивает стабильность при шумных данных.

В целом, это показывает, что Adam — универсальный выбор для больших и нелинейных моделей.

