

Отчет по лабораторной работе №3

Предсказание пропусков медицинских приемов (Medical Appointments No-Show)

0. Описание задачи

Цель работы: Применить методы одномерного анализа данных для улучшения качества прогнозирования модели машинного обучения пропусков медицинских приемов пациентами (No-show prediction).

Почему это важно? Пропуски приёмов — это экономические и организационные потери для медицинских учреждений. Зная, по каким причинам люди пропускают приёмы, мы можем создавать условия и помогать им этого не делать.

Датасет: Medical Appointments No-Show dataset (Mendeley), реальные данные, собранные по данным посещаемости больниц в южной Бразилии

- **Размер исходных данных:** 49,593 записей
- **Количество признаков:** 26 колонок в изначальной версии датасета
- **Целевая переменная:** no_show (бинарная: "yes"/"no")

Описание признаков:

- Демографические: возраст, пол, инвалидность
- Медицинские: специальность, дата рождения, дата первого приема
- Временные: дата и время приема, месяц, год, смена (утро/день)
- Погодные: средняя/максимальная температура, осадки, интенсивность дождя/жары
- Дополнительные: необходимость сопровождения, возрастные категории, инвалидность

Подробное описание колонок:

1. "Specialty": specialty that patient received the treatment;
2. "Appointment Time": appointment time scheduled;
3. "Gender": male or female gender of the patient;
4. "Appointment Date": appointment date scheduled;

5. "No-show": given whether the patient attended the scheduled appointment or not;
6. "No-show Reason": description of the reason why the patient did not attend the scheduled appointment;
7. "Disability": the patient's motor or intellectual disability;
8. "Date of Birth": the patient's date of birth;
9. "Date of Entry into the Service": date of the patient's first appointment at the CER;
10. "City": city where the patient resides;
11. "ICD": identifier of the patient's disease;
12. "Appointment Month";
13. "Appointment Year";
14. "Appointment Shift";
15. "Age": patient's age;
16. "Under 12 years old": patient's age under 12 years old;
17. "Over 60 years old": patient's age over 60 years old;
18. "Patient needs companion": patient's needs companion to go to the appointment;
19. "Patient needs companion": patient's needs companion to go to the appointment;
20. "Average Temperatura Day": Average temperatura in the day of the appointment;
21. "Average Rain Day": Average rain in the day of the appointment;
22. "Max Temperature Day": Maximum temperature in the day of the appointment;
23. "Max Rain Day": Maximum rainfall in the day of the appointment;
24. "Storm Day Before": Heavy rain in the day before the appointment;
25. "Rain Intensity": no rain, weak, moderate or heavy rain in the day of the appointment;
26. "Heat Intensity": cold, heavy cold, warm, heavy warm or mild in the day of the appointment;


1. Первоначальная эффективность модели (базовый уровень)

Используем в качестве отправной точки логистическую регрессию. Мы обучаем простую линейную модель (логистическую регрессию) для задачи классификации и ухода, используя необработанные данные.


Так как данные содержат большое количество пропусков, нам необходимо сделать минимальное заполнение пропусков, для численных признаков заполним значением -999 (что, конечно, методологически неправильно, но мы стараемся сохранить исходный вид данных). Кодировем категориальные признаки, в категориальных колонках NaNs воспримем как -1.

В результате применения логистической регрессии к таким данным получаем метрики классификации $F1 = 0.0$, $ROC-AUC = 0.5731$.

Есть гипотеза, что это вызвано большим дисбалансом классов в целевой переменной.



Полученные результаты:



2. Анализ одномерных данных

Для работы с данными нами был выбран ряд наиболее, как нам кажется, репрезентативных признаков для модели. Это возраст, потребность в сопровождении, тип врача, к которому назначен приём, disabilities (ментальные и физические).

Типы признаков:

- Числовые (5): age, average_temp_day, average_rain_day, max_temp_day, max_rain_day
- Бинарные (4): under_12_years_old, patient_needs_companion, rainy_day_before, storm_day_before
- Категориальные (7): specialty, disability, appointment_month, rain_intensity, heat_intensity, appointment_shift, gender

2.1. Описательная статистика и визуализация

Статистика числовых признаков.

Переменная 'age': средний возраст 18.5 лет, при медиане 11 лет и размахе от 2 до 110 говорит о том, что средняя масса пациентов — это дети и подростки, с длинным хвостом взрослых и пожилых пациентов, вплоть до экстремальных значений до 110 лет. Также в пользу длинного правого хвоста говорит сильная положительная асимметрия (skew). Положительный эксцесс указывает на более острую вершину распределения и тяжелые хвосты, по сравнению с нормальным распределением, то есть в сети есть много наблюдений вокруг среднего, но в то же время есть довольно экстремальные значения параметра, которые могут оказаться выбросами, так что требуется проверить качество данных. Пропусков много, примерно у каждого пятого пациента не заполнен возраст. Это критичный момент для модели: придётся либо аккуратно восстанавливать возраст, либо продумывать, как не потерять эти записи.


Переменная 'average_temp_day': распределение близко к симметричному; есть пропуски: 2.0% наблюдений.

Переменная 'average_rain_day': распределение сильно асимметрично, правосторонняя (длинный правый хвост); остроконечное распределение с тяжёлыми хвостами (высокий риск выбросов); есть пропуски: 2.0% наблюдений.


Переменная 'max_temp_day': распределение близко к симметричному; есть пропуски: 2.0% наблюдений.

Переменная 'max_rain_day': распределение сильно асимметрично, правосторонняя (длинный правый хвост); остроконечное распределение с тяжёлыми хвостами (высокий риск выбросов); есть пропуски: 2.0% наблюдений.





	count	missing	missing_pct	mean	median	std	range	min	25%	75%	max	skew	kurtosis
age	39243.0	10350	20.870	18.522	11.00	19.235	108.00	2.00	8.00	15.00	110.00	2.060	3.161
average_temp_day	48577.0	1016	2.049	19.748	20.06	3.429	19.07	8.94	17.48	22.12	28.01	-0.430	-0.117
average_rain_day	48577.0	1016	2.049	0.190	0.01	0.452	4.77	0.00	0.00	0.15	4.77	4.266	23.972
max_temp_day	48577.0	1016	2.049	23.962	23.90	3.820	22.10	13.30	21.40	26.50	35.40	0.005	-0.223
max_rain_day	48577.0	1016	2.049	1.896	0.20	4.445	45.00	0.00	0.00	1.60	45.00	4.463	27.348




Распределение age по классам no_show




Видим некоторое повторение формы на обоих целевых классах



Также нами были построены распределения числовых переменных в контексте каждого из классов для анализа форм распределений в обоих случаях (подробнее можно увидеть в google collab по ссылке вместе с интерактивными графиками), но например:




Также нами были построены визуализации KDE:



Статистика бинарных признаков

Бинарные значения представлены не в равных соотношениях, но распределения между целевой переменной yes/no сохраняются.





	variable	n	missing	missing_pct	share_of_1
0	under_12_years_old	49593	0	0.0	0.472
1	patient_needs_companion	49593	0	0.0	0.544
2	rainy_day_before	49593	0	0.0	0.981
3	storm_day_before	49593	0	0.0	0.981


Категориальные признаки

Важные моменты:


- **specialty**: 8 категорий, наиболее частые - speech therapy (11,877), psychotherapy (11,675), physiotherapy (9,074)
- **disability**: intellectual (30,882), motor (13,565)
- **appointment_month**: равномерное распределение по месяцам
- **gender**: M (37,583), F (12,003), I (7)




По месяцам видим неравномерное распределение, меньше всего записей на промежуток декабрь-февраль:




Как и везде, тенденция такая, что в колонках сохраняется соотношение:




Видим, что записей на вечер чуть больше:




В основном в южной Бразилии погода умеренная, тёплая или холодная, без дождя.





2.2. Обработка пропущенных значений

Топ колонок по пропущенным значениям:



Исходное состояние:

- age: 10,350 пропусков (20.87%)
- specialty: 7,454 пропусков (15.03%)
- disability: 5,146 пропусков (10.38%)
- Погодные признаки: 1,016 пропусков (2.05%) - консистентны по датам

Мы придерживались идеи, что нам важен каждый сэмпл и лучше заполнить пропуски, чем просто убрать эти записи

Прежде всего, мы сразу преобразовали пропуски или пробельные строки в nan для категориальных признаков

2.2.1. Погодные признаки (average_temp_day, average_rain_day, max_temp_day, max_rain_day)

Исходная проблема:

- 1,016 пропусков (2.05% данных) в 4 погодных признаках
- Пропуски консистентны по датам: если в какой-то день отсутствует значение, то для всех записей этого дня оно отсутствует
- Всего затронуто 32 уникальные даты

Анализ данных:

На самом деле проще удалить 2 процента всех кортежей по признакам average_rain_day, average_temp_day, max_rain_day, max_temp_day, если в них содержатся пропуски значений, чем выстраивать стратегию заполнения.

20. "Average Temperatura Day": Average temperatura in the day of the appointment;

21. "Average Rain Day": Average rain in the day of the appointment;

22. "Max Temperature Day": Maximum temperature in the day of the appointment;

23. "Max Rain Day": Maximum rainfall in the day of the appointment;

Из описания этих четырех признаков понятно, что они в целом зависят от дня appointment_date, поэтому мы проанализировали, есть ли вообще записи с таким же значением appointment_date, но без пропусков, и попытались заполнить пропуски средним значением тех же фичей по тем же датам. Мы исходим из логики, что в день приема были другие пациенты, у которых значение погодных признаков было указано. Однако выяснилось, что если значение отсутствует, то оно отсутствует для всех записей этого дня. Это указывает на системную проблему сбора данных (отсутствие метеорологических данных за эти дни).

Тогда мы выбрали **иерархическое заполнение** с временным окном

Шаг 1 - Поиск в ближайших днях:

- Для каждой записи с пропуском определяется дата приема
- Выполняется поиск значений в окне ± 7 дней от текущей даты

- Поиск идет итеративно: сначала проверяются дни на расстоянии 1, затем 2, и так далее до 7 дней
- При нахождении значения в ближайшем дне, используется среднее значение всех записей этого дня
- Выбирается значение из ближайшего доступного дня (минимизация временного расстояния)

2. Шаг 2 - Сезонное заполнение:

- Если в окне ± 7 дней не найдено значений, используется сезонный подход
- Вычисляется среднее значение признака для соответствующего месяца из всех доступных данных
- Это учитывает сезонные паттерны (например, температура в январе отличается от температуры в июле)

Мы обосновываем это так, что:

- Погодные данные имеют временную корреляцию: значения в соседние дни похожи
- Сезонность: температура и осадки зависят от времени года
- Метод сохраняет естественную структуру временных рядов

Результат:

- Все 1,016 пропусков успешно заполнены
- Статистика после заполнения:
 - `average_temp_day`: mean=19.84°C, std=3.45
 - `average_rain_day`: mean=0.20, std=0.45
 - `max_temp_day`: mean=24.06°C, std=3.85
 - `max_rain_day`: mean=1.97, std=4.44


2.2.2. Возраст (age)

Исходная проблема:


- 10,350 пропусков (20.87% данных) - самый большой процент пропусков
- Возраст критически важен для медицинского анализа

- Распределение возраста асимметрично (skewness=2.06), медиана=11 лет

Missing values percent by column



Визуализация результатов заполнения:



В стратегии заполнения возраста age используется иерархический подход:

1. Вычисляются **медианные значения** возраста для каждой медицинской специальности *specialty*, и для пациентов с пропущенным возрастом, у которых указана **специальность**, пропуски заполняются соответствующей медианой;

Обоснование:

- Разные медицинские специальности обслуживают разные возрастные группы
 - Например, педиатрия - детей, гериатрия - пожилых
 - Медиана более устойчива к выбросам, чем среднее
2. Для случаев, когда специальность неизвестна или не имеет достаточных данных, применяется алгоритм **к-ближайших соседей (KNN)**, который на основе **известных значений возраста у пациентов с аналогичными характеристиками** (специальность, тип инвалидности *disability* и

возрастная категория до 12 лет under_12_years_old) предсказывает пропущенные значения, причем используется взвешенный KNN-регрессор, где более близкие соседи имеют больший вес.

Обоснование:

- Для записей без специальности или с редкими специальностями медиана недоступна
- KNN использует похожесть пациентов по другим признакам
- Взвешенный KNN учитывает близость соседей

Параметры модели:

- $K=5$ (адаптивно: $\min(k, \text{количество доступных примеров})$)
- Веса: `weights='distance'` (близкие соседи имеют больший вес)
- Метрика расстояния: евклидово расстояние по закодированным признакам

Итоговые статистики после заполнения:

- Mean: 17.76 лет
- Median: 11.00 лет
- Std: 17.59
- Min: 2.00
- Max: 110.00

Результат: Все 10,350 пропусков заполнены

2.2.3. Специальность (specialty)


Исходная проблема:

- 7,454 пропуска (15.03% данных)
- 8 уникальных категорий специальностей
- Специальность важна для понимания контекста приема

В стратегии заполнения специальности specialty используется алгоритм k-ближайших соседей (KNN):

1. В качестве признаков для определения похожести пациентов используются возраст age, тип инвалидности disability и возрастная категория до 12 лет under_12_years_old;
2. Пропущенные значения в признаках заполняются медианными значениями из обучающей выборки.

Выбранный метод: KNN-классификация



Признаки для классификации:

- age - возраст пациента
- disability - тип инвалидности (intellectual/motor)
- under_12_years_old - возрастная категория

2.2.4. Ограничения по здоровью (disability)

Исходная проблема:

- 5,146 пропусков (10.38% данных)
- 3 категории: intellectual, motor, и редкая категория (9 записей)
- Сильная корреляция с другими признаками

Сначала для каждой specialty, содержащей более 50 записей с известной disability, определяется доминирующая категория (intellectual или motor), но только если она составляет более 70% случаев в данной специальности.

Данные группируются по возрастным категориям (дети до 12 лет, подростки 12-18, молодые 18-30, средний возраст 30-50 и старше 50), и для каждой возрастной группы с


более чем 100 записями также выявляется доминирующий тип инвалидности disability, если он превышает 65% случаев в группе.

В результате получаем два словаря: соответствия между специальностями и преобладающим типом disability, а также между возрастными группами и характерной для них disability, которые затем используются для более осознанного заполнения пропусков

Обоснование:

- Инвалидность имеет четкие паттерны зависимости от специальности и возраста
- Например, определенные специальности преимущественно работают с одним типом инвалидности
- Дети чаще имеют intellectual disability, взрослые - motor disability

Приоритет правил: Сначала проверяется правило по специальности (более специфичное). Если специальность не имеет правила, проверяется возрастная группа. Если оба правила недоступны, значение остается пропущенным (но таких случаев не было)



2.2.5 Итоговые результаты обработки пропусков

Признак	Исходные пропуски	Процент	Метод заполнения	Заполнено	Осталось
Погодные признаки	1,016	2.05%	Иерархическое (временное окно + сезонность)	1,016	0

age	10,350	20.87%	Медиана по специальности + KNN	10,350	0
specialty	7,454	15.03%	KNN-классификация	7,454	0
disability	5,146	10.38%	Правила на основе паттернов	5,146	0
Всего	23,966	(некорректно вычислять)	Комбинированный подход	23,966	0

2.3. Выбросы

2.3.1 Методы детекции

IQR метод (для age, average_rain_day, max_rain_day):

- Устойчив к асимметричным распределениям
- Границы: $Q1 - 1.5 \times IQR$, $Q3 + 1.5 \times IQR$
- Стратегия: обрезка до границ (capping)

Z-score метод (для average_temp_day, max_temp_day):

- Подходит для нормальных распределений
- Порог: $|z| > 3$
- Стратегия: удаление выбросов

2.3.2 Результаты обработки

Признак	IQR выбросы	Z-score выбросы	Пересечение	Стратегия	Обработано
age	7,095	1,094	1,094	Intersection- capped	1,094
average_rain_day	7,212	1,300	1,300	Intersection- capped	1,300
max_rain_day	6,546	1,196	1,196	Intersection- capped	1,196
average_temp_day	318	231	231	Z-score-removed	231
max_temp_day	153	0	0	Intersection- removed	0

Итог: Удалено 231 строка, финальный размер: 49,362 записи

2.4. Выбросы

2.4.1. Анализ необходимости преобразований

Не требуют преобразования:

- `age`: естественная интерпретация, преобразование разрушит смысл
- `average_temp_day`, `max_temp_day`: близки к нормальному распределению

Требуют преобразования:

- `average_rain_day`, `max_rain_day`: сильная правосторонняя асимметрия, много нулей, длинный хвост

Бинарные переменные не требуют никакого преобразования. Это включает такие признаки, как индикаторы шторма и другие погодные признаки. Их дисбаланс в значениях не является статистической проблемой.

С преобразованиями для `average_rain_day` и `max_rain_day` обнаружились интересные вещи. Почти вся масса у нуля и короткий хвост вправо — это zero-inflated распределение (много нулей + непрерывный положительный компонент). Трансформации вроде лог/Box-Cox не уберут дискретную массу в нуле, и она несёт смысл. Было применено преобразование к неотрицательной части и ограничение верхних значений 95 перцентилем. После ограничения выбросов было применено логарифмическое преобразование, что позволило уменьшить правостороннюю асимметрию распределений. То есть мы сделали capping и log-transformation, чтобы уменьшить асимметрию.

Были реализованы собственные логарифмическое преобразование (`log1p`) и преобразование Yeo-Johnson. Yeo-Johnson преобразование было протестировано, но отклонено из-за мультимодальности распределений осадков

2.4. Масштабирование

В масштабировании была применена стандартизация по формуле: $(x - \text{mean}) / \text{std}$

Она была применена к числовым признакам: `age`, `average_temp_day`, `max_temp_day`, `max_rain_day`, `average_rain_day`

Это стандартная практика для логистической регрессии, которая обеспечивает устойчивость к выбросам.

2.5.1. Дополнительная очистка данных

Проверка логической согласованности производных признаков

В датасете присутствуют бинарные признаки, логически связанные с age:

- **under_12_years_old** (должен быть 1, если $\text{age} < 12$)
- **over_60_years_old** (должен быть 1, если $\text{age} > 60$)

После очистки возраста необходимо привести эти характеристики к ожиданиям.

Обнаружены и исправлены два типа несоответствий:

1. **under_12_years_old = 1, но $\text{age} \geq 12 \Rightarrow$ признак изменён на 0**
2. **age < 12, но $\text{under_12_years_old} = 0 \Rightarrow$ признак изменён на 1**

Аналогично были исправлены две группы ошибок:

1. **over_60_years_old = 1, но $\text{age} \leq 60 \Rightarrow$ исправлено на 0**
2. **age > 60, но $\text{over_60_years_old} = 0 \Rightarrow$ исправлено на 1**

3. Повторный эксперимент

One-Hot Encoding был применён к 7 категориальным признакам, было создано множество бинарных признаков

Предикторы:

- Числовые (5): стандартизированные возраст и погодные показатели
- Бинарные (4): возрастные категории, погодные индикаторы, необходимость сопровождения
- One-Hot Encoded: все категории из 7 исходных признаков

Мы помнили о проблеме балансировки классов и провели эксперимент без балансировки, но с улучшенным подходом к данным. Результаты: F1-score: 0.0, ROC-AUC: 0.5931. Результаты стали незначительно лучше, но всё же недостаточно.

Далее мы опробовали простую undersampling политику, результаты F1 score: 0.5745 ROC-AUC: 0.6014. Теперь модель не предсказывает лишь мажоритарный класс, но от этого точность не стала лучше.

Также мы опробовали простую oversampling политику с повторами миноритарного класса, которая привела к результатам: F1 score: 0.5798, ROC-AUC: 0.6054

Кроме того, были опробованы варианты андерсэмплинга с подбором параметров C/penalty/solver через GridSearchCV (F1-score: 0.2437, ROC-AUC: 0.5948) и оверсэмплинга с подбором с использованием SMOTE (F1-score: 0.2426, ROC-AUC: 0.5954) — более умный oversampling, который не дублирует строки, а генерирует новые точки minority-класса, интерполируя их между существующими соседями. К последним двум методам была применена перекрёстная валидация 5-fold с сохранением баланса.

Ради интереса, мы также сравнили результаты с Random Forest Classifier с class_weight="balanced". F1-score: 0.1239, ROC-AUC: 0.6371

4. Выводы

В этой работе мы применили методы одномерного анализа для улучшения качества модели. Действительно, качество модели улучшилось незначительно, но улучшилось. Мы выяснили, что это достаточно «потолочные» метрики для данного набора данных. Стоит предположить, что вопрос может быть в качестве данных и в том, что мы не учитываем ещё ряд факторов, которые могут влиять.

Сравнивая с другими контрибьюторами по более чистому датасету, можно увидеть ROC AUC: 0.67, что не так далеко от нашего результата на простых моделях. Это указывает на корректность наших выборов, но, видимо, фундаментально задача плохо предсказуемая при данной структуре данных.