

ИТМО
MFML
Lab 3 & Lab 4
Team 7

Ишутина, Леоненко, Лопатенко, Терентьева


The data and the task

Мы работали с датасетом Medical Appointments No-Show - это реальные данные о записях пациентов к врачу.

Задача: предсказать, придет ли человек на приём или нет (No-show = no - не пришёл, yes - пришёл).

Целевая переменная: No-show.

Распределение целевой переменной no_show



#	Column	Non-Null Count	Dtype
0	specialty	42139 non-null	object
1	appointment_time	49593 non-null	object
2	gender	49593 non-null	object
3	appointment_date	49593 non-null	object
4	no_show	49593 non-null	object
5	no_show_reason	1737 non-null	object
6	disability	44456 non-null	object
7	date_of_birth	39272 non-null	object
8	entry_service_date	44438 non-null	object
9	city	44412 non-null	object
10	icd	10717 non-null	object
11	appointment_month	49593 non-null	object
12	appointment_year	49593 non-null	int64
13	appointment_shift	49593 non-null	object
14	age	39243 non-null	float64
15	under_12_years_old	49593 non-null	int64
16	over_60_years_old	49593 non-null	int64
17	patient_needs_companion	49593 non-null	int64
18	average_temp_day	48577 non-null	float64
19	average_rain_day	48577 non-null	float64
20	max_temp_day	48577 non-null	float64
21	max_rain_day	48577 non-null	float64
22	rainy_day_before	49593 non-null	int64
23	storm_day_before	49593 non-null	int64
24	rain_intensity	49593 non-null	object
25	heat_intensity	49593 non-null	object

dtypes: float64(5), int64(6), object(15)
memory usage: 9.8+ MB

Naïve approach

Модель: Logistic Regression



Данные: Без балансировки классов

Результаты:

- F1-score: 0.0


- ROC-AUC: 0.5731

Вывод: результаты близки к случайному угадыванию из-за дисбаланса классов




Одномерный анализ: распределения ИТМО


	count	missing	missing_pct	mean	median	std	range	min	25%	75%	max	skew	kurtosis
age	39243.0	10350	20.870	18.522	11.00	19.235	108.00	2.00	8.00	15.00	110.00	2.060	3.161
average_temp_day	48577.0	1016	2.049	19.748	20.06	3.429	19.07	8.94	17.48	22.12	28.01	-0.430	-0.117
average_rain_day	48577.0	1016	2.049	0.190	0.01	0.452	4.77	0.00	0.00	0.15	4.77	4.266	23.972
max_temp_day	48577.0	1016	2.049	23.962	23.90	3.820	22.10	13.30	21.40	26.50	35.40	0.005	-0.223
max_rain_day	48577.0	1016	2.049	1.896	0.20	4.445	45.00	0.00	0.00	1.60	45.00	4.463	27.348




Распределение average_rain_day по классам no_show




Распределение age по классам no_show



Распределение average_temp_day по классам no_show




Распределение max_rain_day по классам no_show



Одномерный анализ: пропуски

Доля пропусков по числовым и бинарным признакам



	column	missing_count	missing_percent
0	age	10350	20.869881
9	specialty	7454	15.030347
10	disability	5146	10.376464
2	average_rain_day	1016	2.048676
1	average_temp_day	1016	2.048676
4	max_rain_day	1016	2.048676
3	max_temp_day	1016	2.048676

Одномерный анализ: результаты

Модель: Logistic Regression

Данные:

- Балансировка классов методом upsampling меньшинства
- Размер после балансировки удвоен

Результаты:

- F1 score: 0.5798
- ROC-AUC: 0.6054

Вывод: значительное улучшение от baseline

РАСПРЕДЕЛЕНИЕ КЛАССОВ

Train set - Class 0: 24121, Class 1: 3241

Test set - Class 0: 6031, Class 1: 810

Fitting 3 folds for each of 3 candidates, totalling 9 fits

Лучшие параметры: {'C': 1, 'max_iter': 500, 'penalty': 'l2', 'solver': 'saga'}

Лучший F1-score (CV): 0.5739


Результаты на тестовой выборке:

F1-score: 0.2437

ROC-AUC: 0.5948

Classification Report:

	precision	recall	f1-score	support
0	0.91	0.57	0.70	6031
1	0.15	0.58	0.24	810
accuracy			0.57	6841
macro avg	0.53	0.58	0.47	6841
weighted avg	0.82	0.57	0.65	6841



Одномерный анализ: результаты

Модель: SMOTE + Pipeline + RandomizedSearchCV

Данные:

- Параметры: `n_estimators=200`, `class_weight="balanced"`
- Данные: без балансировки (использован встроенный баланс)



Результаты:

- F1-score: 0.2426
- ROC-AUC: 0.5948

Вывод: Random Forest показал лучший ROC-AUC, но худший F1-score из-за дисбаланса классов


Classification Report:

	precision	recall	f1-score	support
0	0.91	0.58	0.71	6031
1	0.15	0.57	0.24	810
accuracy			0.58	6841
macro avg	0.53	0.57	0.47	6841
weighted avg	0.82	0.58	0.65	6841




Многомерный анализ: корреляция

Корреляционная матрица (Pearson) для признаков и no_show



Многомерный анализ: scatt + vif



Scatterplot matrix для числовых и бинарных признаков (цвет = no_show)



	feature	VIF
5	under_12_years_old	15.695181
6	patient_needs_companion	9.741298
0	age	5.261978
3	max_temp_day	4.818439
1	average_temp_day	4.762492
2	average_rain_day	3.805514
4	max_rain_day	3.720805
7	rainy_day_before	0.000000
8	storm_day_before	0.000000



Многомерный анализ: PCA

	PCA_1	PCA_2	appointment_date	no_show
0	-11.147034	-11.742321	2016-06-20	no
1	42.840257	-12.128357	2016-06-20	no
2	-5.170485	-11.782835	2016-06-20	no
3	-10.175766	-11.750998	2016-06-20	no
4	8.357403	-11.882724	2016-06-20	no




Многомерный анализ: t-SNE + UMAP

Кластеры пациентов (k-means) на UMAP-пространстве цвет = кластер, символ = no_show



Многомерный анализ: факторы


Нагрузки переменных на скрытые факторы (Factor Analysis)



	Factor1	Factor2	Factor3
age	-0.034798	1.784530e-03	5.858038e-01
average_temp_day	0.143417	1.697412e-01	1.835907e-02
average_rain_day	0.168237	9.135989e-01	-1.844175e-05
max_temp_day	0.137886	1.337899e-02	2.322775e-02
max_rain_day	0.205950	9.782819e-01	-1.479693e-05
rain_intensity_value	0.211727	9.711921e-01	-1.329497e-05
under_12_years_old	0.030521	-1.565141e-03	-9.719466e-01
rainy_day_before	-1.000000	1.881509e-10	-2.626068e-13
storm_day_before	-1.000000	1.881509e-10	-2.626068e-13
patient_needs_companion	-0.047115	6.524966e-03	-5.818628e-01

Многомерный анализ: K-means

Кластеры пациентов (k-means) на UMAP-пространстве цвет = кластер, символ = no_show




Многомерный анализ: результаты

Модель: Logistic Regression

Результаты:

- F1 score: 0.5787
- ROC-AUC: 0.6008

Вывод: большого прироста многомерный анализ не дал



Многомерный анализ: результаты



Модель: SMOTE + Pipeline + RandomizedSearchCV

Результаты:

- F1-score: 0.0
- ROC-AUC: 0.5731

Вывод: результаты близки к случайному угадыванию из-за дисбаланса классов