

Отчет по лабораторной работе №4

Предсказание пропусков медицинских приемов (Medical Appointments No-Show)

0. Описание задачи

Цель работы: применить методы многомерного анализа данных для улучшения качества прогнозирования модели машинного обучения пропусков медицинских приемов пациентами (No-show prediction).

Почему это важно? Пропуски приёмов - это экономические и организационные потери для медицинских учреждений. Зная, по каким причинам люди пропускают приёмы, мы можем создавать условия и помогать им этого не делать.

Датасет: Medical Appointments No-Show dataset (Mendeley), реальные данные, собранные по данным посещаемости больниц в южной Бразилии

- **Размер исходных данных:** 49,593 записей
- **Количество признаков:** 26 колонок в изначальной версии датасета
- **Целевая переменная:** no_show (бинарная: "yes"/"no")

Описание признаков:

- Демографические: возраст, пол, инвалидность
- Медицинские: специальность, дата рождения, дата первого приема
- Временные: дата и время приема, месяц, год, смена (утро/день)
- Погодные: средняя/максимальная температура, осадки, интенсивность дождя/жары
- Дополнительные: необходимость сопровождения, возрастные категории, инвалидность

Подробное описание колонок:

1. "Specialty": specialty that patient received the treatment;
2. "Appointment Time": appointment time scheduled;
3. "Gender": male or female gender of the patient;
4. "Appointment Date": appointment date scheduled;

5. "No-show": given whether the patient attended the scheduled appointment or not;
6. "No-show Reason": description of the reason why the patient did not attend the scheduled appointment;
7. "Disability": the patient's motor or intellectual disability;
8. "Date of Birth": the patient's date of birth;
9. "Date of Entry into the Service": date of the patient's first appointment at the CER;
10. "City": city where the patient resides;
11. "ICD": identifier of the patient's disease;
12. "Appointment Month";
13. "Appointment Year";
14. "Appointment Shift";
15. "Age": patient's age;
16. "Under 12 years old": patient's age under 12 years old;
17. "Over 60 years old": patient's age over 60 years old;
18. "Patient needs companion": patient's needs companion to go to the appointment;
19. "Patient needs companion": patient's needs companion to go to the appointment;
20. "Average Temperatura Day": Average temperatura in the day of the appointment;
21. "Average Rain Day": Average rain in the day of the appointment;
22. "Max Temperature Day": Maximum temperature in the day of the appointment;
23. "Max Rain Day": Maximum rainfall in the day of the appointment;
24. "Storm Day Before": Heavy rain in the day before the appointment;
25. "Rain Intensity": no rain, weak, moderate or heavy rain in the day of the appointment;
26. "Heat Intensity": cold, heavy cold, warm, heavy warm or mild in the day of the appointment;


1. Введение

После одномерного анализа и базовых моделей логистической регрессии стало понятно, что линейные связи отдельных признаков с целевой переменной `no_show` очень слабы, а задача страдает от сильного дисбаланса классов и пропусков в ключевых переменных, прежде всего в возрасте и специальности врача. Для более глубокого понимания структуры данных и возможного улучшения моделей был проведён многомерный анализ, включающий корреляционный анализ, оценку мультиколлинеарности (VIF), методы понижения размерности (PCA, t-SNE, UMAP), факторный анализ, кластеризацию k-means, генерацию взаимодействий и полиномиальных признаков, а также построение байесовской сети зависимостей. Цель этого этапа состояла не только в улучшении метрик модели, но и в том, чтобы выявить избыточные или дублирующие признаки, скрытые факторы и возможные «естественные» группы пациентов, различающихся по риску неявки.

2. Многомерный анализ и улучшения по методам


2.1 Корреляции, scatter-matrix и VIF

Корреляционная матрица (Pearson) для признаков и `no_show`



На матрице Пирсона практически все корреляции с `no_show` оказались близки к нулю: по модулю не выше 0.03–0.04, что подтверждает отсутствие сильных линейных предикторов неявки. Зато между признаками выявились кластеры высокой взаимосвязи: `average_temp_day` и `max_temp_day` ($r \approx 0.88$), `average_rain_day` и `max_rain_day` ($r \approx 0.84$), а также почти идеальная корреляция между `rainy_day_before` и `storm_day_before` ($r \approx 1.0$); бинарный индикатор `under_12_years_old` ожидаемо сильно зависел от возраста и потребности в сопровождении.

Scatterplot matrix для числовых и бинарных признаков (цвет = no_show)



Scatter-матрица подтвердила эти наблюдения визуально и показала, что точки классов no_show = yes/no сильно перекрываются во всех двумерных проекциях. Важно заметить, что окончательных выводов мы здесь не делаем – это предположение, которое мы впоследствии проверим с помощью иных методов.

Анализ VIF выявил критическую мультиколлинеарность: $VIF \approx 15.7$ у under_12_years_old, ≈ 9.7 у patient_needs_companion и >5 у возраста, тогда как для погодных признаков значения были умеренными. На основе этих результатов из набора признаков для моделей были исключены наиболее дублирующие переменные (например, under_12_years_old при сохранении возраста, одна из пар storm_day_before/rainy_day_before, а также часть сильно коррелирующих

температурных и дождевых показателей), что уменьшило мультиколлинеарность и сделало логистическую регрессию более устойчивой.

2.2 Анализ методом главных компонент (PCA)

Метод главных компонент (Principal Component Analysis, PCA) использовался для уменьшения размерности признакового пространства и выявления основных направлений вариативности в данных, прежде всего с учётом сильной корреляции между числовыми и бинарными признаками (возраст, индикаторы возраста, погодные параметры). Идея PCA заключается в том, чтобы заменить исходные (часто коррелирующие) признаки небольшим числом ортогональных линейных комбинаций - главных компонент, каждая из которых объясняет максимально возможную долю дисперсии данных при условии ортогональности к предыдущим компонентам. Это позволяет одновременно бороться с мультиколлинеарностью и упростить структуру данных перед моделированием, не теряя большую часть информации.

В нашем случае PCA рассматривался как инструмент исследовательского анализа, а не как обязательный этап построения признаков для финальной модели: нас интересовало, действительно ли в наборе данных присутствует несколько «осей» вариации (например, возрастная, погодная, клиническая) или же почти всё изменчивое поведение сосредоточено в одном–двух измерениях.




График «Explained variance per component» показывает, что первая главная компонента объясняет около 0.88–0.90 общей дисперсии, вторая - ещё примерно 0.08, тогда как вклад третьей и последующих компонент быстро убывает до значений порядка 0.01 и менее. Кумулятивный график подтверждает: уже две компоненты дают более 0.98 объяснённой дисперсии, а добавление компонент с 3-й по 10-ю увеличивает суммарную долю всего на доли процента, что указывает на сильную «одномерность» структуры данных. Это означает, что почти вся изменчивость наблюдений описывается одним–двумя направлениями в пространстве признаков, а остальные компоненты в основном подстраиваются под шум и редкие комбинации категориальных индикаторов.

При выборе числа компонент для интерпретации использовались два критерия: «локоть» на графике дисперсии (резкий излом между второй и третьей компонентой) и порог суммарной объяснённой дисперсии 95–98%. Оба критерия дают одно и то же решение: достаточно анализировать первые 2–3 компоненты, остальные напоминают скорее локальные поправки для частных групп пациентов. В моделировании мы не использовали компоненту-фичи напрямую (модели строились на очищенном исходном пространстве), но понимание вклада компонент помогло принять решения об удалении избыточных переменных.

2.3 Анализ методом главных компонент (PCA)

Для интерпретации мы рассмотрели нагрузки (component loadings) - коэффициенты при исходных признаках в каждой компоненте. Первая компонента (PC1) почти полностью определяется возрастом: загрузка age $\approx$ 0.999, при этом `under_12_years_old` и `disability_intellectual` имеют небольшие, но согласованные по знаку вклады. Это позволяет трактовать PC1 как «возрастную ось», которая отделяет взрослых пациентов от детей и одновременно частично учитывает связь детского возраста с интеллектуальной инвалидностью. С точки зрения структуры данных, именно возраст объясняет подавляющую часть вариации профилей пациентов, что согласуется с описательной статистикой и факторным анализом.

Вторая компонента (PC2) отражает температурный режим: максимальные нагрузки у `max_temp_day` (около 0.75) и `average_temp_day` (около 0.65), с более слабым вкладом `heat_intensity_cold`. Таким образом, PC2 можно интерпретировать как «ось температуры в день приёма»: слева - относительно холодные дни, справа - тёплые и

жаркие. В совокупности PC1 и PC2 задают двумерное пространство, где первая координата отвечает за возрастной профиль пациента, а вторая - за температурные условия в день визита.



Третья и четвёртая компоненты (PC3 и PC4) в большей степени связаны с осадками и интенсивностью дождя. В PC3 наибольшие загрузки у `average_temp_day`, `max_temp_day` и `max_rain_day`, а в PC4 доминируют `max_rain_day`, `rain_intensity_value` и снова `average_temp_day`. Эти компоненты можно описать как дополнительные «тонкие» оси погоды, различающие комбинации температуры и силы дождя - например, умеренный дождь при средней температуре против кратковременных ливней при высокой температуре. Их вклад в дисперсию уже мал, но они подтверждают важность погодного блока как второго по значимости после возраста источника вариации.

Поздние компоненты (PC5–PC10) захватывают более сложные сочетания категориальных признаков и отражают узкие профили пациентов. Так, PC5 комбинирует смену приёма (`appointment_shift_morning/afternoon`) и моторную инвалидность, PC6 связан с полом пациента (`gender_M`, `gender_F`) и дневной сменой, PC7 - с интенсивностью тепла (`heat_intensity_mild/cold/warm`), PC8 - с сочетанием детского возраста, необходимости сопровождения и психотерапии, а PC9–PC10 в основном отражают различные комбинации специальностей (психотерапия, физиотерапия, логопедия) и моторной инвалидности. Эти компоненты полезны для качественного описания «тонких» групп, но их объяснённая дисперсия крайне мала, поэтому использование их как признаков в моделях не даёт заметного выигрыша и может даже подстраиваться под шум.

2.4 t-SNE и UMAP

Метод главных компонент показал, что первый компонент объясняет около 88–90% дисперсии, второй добавляет ещё порядка 7–8%, а вклад последующих быстро стремится к нулю; суммарная объяснённая дисперсия уже к двум компонентам превышает 0.98. Основным вкладчиком в PC1 оказался возраст (нагрузка ≈ 0.999), а также с меньшими весами - индикатор `under_12_years_old` и интеллектуальная инвалидность; PC1 можно интерпретировать как «возрастную ось». PC2 в основном описывал температурный режим: наибольшие нагрузки у `max_temp_day` и `average_temp_day`, дополнительно участвовал индикатор холодной погоды. Поздние

компоненты (PC5–PC10) фиксировали узкие паттерны по сменам, полу, видам терапии и деталям температурно-погодных условий, но объясняли весьма малую долю дисперсии и не использовались в финальных моделях. Нелинейные проекции t-SNE и UMAP, построенные по стандартизированным признакам, не выявили чётко отделённых кластеров неявок: точки классов «пришёл» и «не пришёл» заполняют пространство почти равномерно, без визуально выделенных «островков» повышенного риска пропуска.



2.5 Факторный анализ и кластеризация


Факторный анализ с тремя факторами дал более интерпретируемое представление: первый фактор получил почти единичные отрицательные нагрузки от storm_day_before и rainy_day_before и умеренные нагрузки от дождевых показателей, поэтому интерпретирован как «погода с дождём накануне»; второй фактор доминируется max_rain_day, rain_intensity_value и average_rain_day и отражает «интенсивность осадков в день приёма»; третий фактор описывается положительной нагрузкой на age (≈ 0.59) и сильной отрицательной на under_12_years_old (≈ -0.97), что соответствует оси «детский возраст vs взрослый». Это позволило компактно представить метеорологические и возрастные характеристики тремя латентными переменными, снижая размерность без существенной потери информации.

Нагрузки переменных на скрытые факторы (Factor Analysis)



На UMAP-пространстве были запущены k-means-кластеры ($k=3$): кластеры хорошо разделялись по типу терапии, инвалидности и возрасту, однако внутри каждого из них доли no_show=yes и no_show=no оставались близкими, без «кластера неявок», что указывает на слабую связь естественных групп пациентов с целевой переменной.

Кластеры пациентов (k-means) на UMAP-пространстве цвет = кластер, символ = no_show



2.6 Генерация взаимодействий, полиномиальные признаки и отбор

На следующем этапе были сгенерированы осмысленные для конкретной задачи взаимодействия: индикаторы выходного дня и недели, возрастные группы, композитные признаки «плохая погода» и «комфортная погода», сочетания детского возраста и дождя (`child_rain`), пожилого возраста и плохой погоды (`elderly_bad_weather`), инвалидности и неблагоприятных условий, а также агрегации по «сложным» и «детским» специальностям; дополнительно были введены полиномиальные признаки для возраста и температур. Это увеличило размерность до примерно 70–80 признаков, поэтому использовались рекурсивное исключение признаков (RFE) и регуляризованные модели для отбора наиболее информативных комбинаций. Наконец, была построена гибридная байесовская сеть (через пакет BAMT): категориальные признаки кодировались числами, непрерывные - дискретизировались, структура сети подбиралась методом hill climbing по BIC/MI, а затем по сети проводился байесовский вывод (MAP-оценки и credible-интервалы) для вероятности `no_show` при разных наборах условий. Этот шаг носил в большей степени исследовательский характер и позволил уточнить качественные зависимости (например, усиление риска при сочетании инвалидности, плохой погоды и детского возраста), но не приводил к отдельной конкурентной предсказательной модели.

2.7 Байесовская сеть зависимостей

Для построения байесовской сети использовался гибридный подход, позволяющий одновременно работать с категориальными и непрерывными переменными, поэтому данные предварительно были приведены к смешанному дискретно-континуальному формату. Категориальные признаки (`specialty`, `disability`, `appointment_shift`, `rain_intensity`, `heat_intensity`, возрастные и погодные индикаторы) кодировались целыми числами; редкие категории при необходимости объединялись, чтобы избежать слишком разреженных распределений условных вероятностей. Непрерывные признаки (возраст, средняя/максимальная температура, осадки) дискретизировались на интервалы по квантилям или осмысленным порогам (например, детский/взрослый возраст, умеренная/экстремальная температура, отсутствие/наличие осадков), что позволило описывать их через конечные множества состояний в узлах сети. Такая подготовка необходима, поскольку реализованный в пакете BAMT тип сети ориентирован на

дискретные и кусочно-непрерывные распределения и чувствителен к сильно несбалансированным или непрерывным признакам без разбиения.

Структура сети - то есть набор вершин и направление рёбер между ними - подбиралась автоматически методом HillClimbing, который итеративно добавляет, удаляет или переориентирует дуги и принимает те изменения, которые улучшают выбранный критерий качества (BIC или взаимная информация). При обучении мы позволили образовываться ребрам между всеми признаками, но целевую переменную `no_show` рассматривали как потомка (`child-узел`), то есть интерес представляли входящие дуги к ней от предикторов. На полученной структуре вокруг узла `no_show` появились связи от возрастных и инвалидных признаков, а также от некоторых погодных и организационных факторов, что согласуется с гипотезами предметной области (детский возраст, необходимость сопровождения, моторная инвалидность и неблагоприятная погода потенциально увеличивают риск неявки). После фиксации структуры для каждого узла были оценены параметры - условные распределения вероятностей: для дискретных переменных в виде таблиц условных вероятностей, для гибридных узлов - в виде смешанных распределений, поддерживаемых BAMB.

Визуальный анализ структуры сети показал, что вокруг `no_show` концентрируются дуги от возрастных признаков (`under_12_years_old/age`), типов инвалидности (в первую очередь `motor disability`), необходимости сопровождения (`patient_needs_companion`) и ряда погодных индикаторов, то есть сеть подтверждает мультифакторную природу неявок. При условных запросах к сети вероятность неявки обычно возрастала при сочетании детского возраста, инвалидности и неблагоприятной погоды или «сложных» специальностей (психо- и физиотерапия), однако изменения были умеренными: модель показывала рост риска относительно базового уровня, но не давала экстремально высоких вероятностей для каких-то отдельных конфигураций. В терминах предсказательной способности байесовская сеть не превзошла логистическую регрессию: ROC-AUC и F1-мера оставались в тех же пределах порядка 0.6 и 0.2–0.25 соответственно, что отражает ту же фундаментальную ограниченность набора данных. Тем не менее, в отличие от чисто дискриминативных моделей, байесовская сеть дала более интерпретируемое вероятностное описание: можно явно увидеть, какие комбинации факторов «тянут» вероятность `no_show` вверх или вниз, и как изменяется распределение риска при варьировании отдельных предикторов.

2.8 Результаты: базовая, одномерная и многомерная модели

Исходная логистическая регрессия на минимально обработанных данных с простым заполнением пропусков и one-hot-кодированием категориальных признаков показала $F1=0.0$ и $ROC-AUC=0.5731$: модель практически всегда предсказывала мажоритарный класс и не умела находить неяви.

Очистка признакового пространства на основе корреляций и VIF (удаление `under_12_years_old`, сокращение набора погодных индикаторов, выбор одного из сильно коррелирующих признаков), использование стандартизации и регуляризованной логистической регрессии в пайплайнах со SMOTE и RandomizedSearchCV привели к более устойчивым, но не радикально лучшим метрикам: $F1$ на несбалансированном тесте стабилизировалась на уровне 0.24–0.25, $ROC-AUC$ - около 0.60. Добавление факторных и полиномиальных признаков, а также отобранных взаимодействий (таких как `elderly_bad_weather`, `disabled_bad_weather`, `complex_specialty`) не дало значимого прироста: не удалось выйти за потолок $ROC-AUC \approx 0.60-0.61$ и $F1 \approx 0.25$ при адекватном балансе между `precision` и `recall`. Таким образом, многомерный анализ позволил сделать модели чуть более интерпретируемыми и стабильными, но не снял фундаментальных ограничений предсказуемости по имеющимся данным.

Многомерный анализ подтвердил, что основная сложность задачи - не в «плохой модели», а в слабой связи наблюдаемых признаков с событием неяви: ни отдельные переменные, ни их линейные или нелинейные комбинации не дают высокого отдельного сигнала между классами `no_show=yes` и `no_show=no`. При этом анализ корреляций, VIF, PCA и факторной структуры показал значительную избыточность внутри предикторов: группы сильнокоррелирующих температурных и дождевых признаков, дублирование возрастной информации бинарными индикаторами, тесная связь детского возраста, инвалидности и необходимости сопровождения. Удаление или агрегация таких признаков уменьшило мультиколлинеарность, упростило модель и сделало коэффициенты более интерпретируемыми, а факторный анализ и PCA позволили компактно описать погодный и возрастной контекст несколькими латентными переменными. Метрики качества по сравнению с одномерным этапом практически не изменились, но многомерный анализ дал ценное понимание структуры данных и показал ограниченность попыток «выжать» из текущих признаков точный

прогноз неявок. В практическом смысле это означает, что для существенного улучшения качества потребуется обогащать датасет дополнительной информацией - о логистике, мотивации и социальных факторах пациентов, - а не только усложнять используемые модели.